Universiteti i Prishtinës “Hasan Prishtina”

Fakulteti i Inxhinierisë Elektrike dhe Kompjuterike



Dokumentim teknik i projektit

Lënda: Analiza e të dhënave

Titulli i projektit:

Analiza Përshkruese dhe Modelimi me Regresion Linear i Performancës Akademike të Nxënësve

Profesori / Asistenti	Studenti / Studentët
Prof. Asst. Dr. Mërgim H. HOTI	Valon Hajredini valon.hajredini2@student.uni-pr.edu
	Avdi Shabani avdi.shabani@student.uni-pr.edu

Prishtinë, 2026

Përmbajtja

Abstrakti **3**

I. Hyrje **4**

II. Qëllimi i punimit **5**

III. Pjesa kryesore **6**

3.1. Dataset-i dhe klasifikimi sipas Stevens **6**

3.2. Pastrimi i të dhënave dhe analiza përshkruese **7**

3.3. Modelimi me regresion linear **8**

3.4. Analiza e mbetjeve (residuals) **9**

IV. Konkluzione (Përfundim) **9**

Referencat **10**

Abstrakti

Performanca akademike e nxënësve është një tregues i rëndësishëm për vlerësimin e progresit arsimor dhe identifikimin e modeleve të arritjes së rezultateve. Ky punim analizon lidhjen ndërmjet notave të periudhës së parë (G1), periudhës së dytë (G2) dhe notës përfundimtare (G3) për 395 nxënës në lëndën e matematikës, duke përdorur dataset-in Student Performance nga UCI Machine Learning Repository. Studimi nis me formulimin e pyetjes kërkimore dhe hipotezave, klasifikimin e 33 variablave sipas Stevens, kontrollin e cilësisë së të dhënave dhe statistikat përshkruese. Më pas paraqiten vizualizime, matrica e korrelacionit dhe dy modele të regresionit linear me metodën Ordinary Least Squares (OLS). Modeli i thjeshtë e shpjegon notën përfundimtare vetëm nga G2, ndërsa modeli i shumëfishtë përdor G1 dhe G2 së bashku. Në literaturë janë studiuar edhe metoda të tjera të nxjerrjes së njohurive dhe parashikimit të suksesit shkollor; këtu zgjidhet regresioni linear për interpretueshmërinë e tij dhe për krahasimin transparent të koeficientëve. Rezultatet tregojnë korrelacion të fortë pozitiv mes G2 dhe G3 ($r = 0.905$). Modeli i thjeshtë arrin $R^2 = 0.8188$, kurse modeli i shumëfishtë $R^2 = 0.8222$; pra shtimi i G1 sjell vetëm një përmirësim të vogël. Të dy koeficientët e modelit të shumëfishtë janë statistikisht domethënës në nivelin 0.05. Analiza e mbetjeve zbulon devijime nga normaliteti dhe disa gabime të mëdha negative. Prandaj rezultatet mbështesin hipotezën për lidhjen mes notave, por nuk provojnë shkakësi dhe nuk përbëjnë verifikim të aftësisë parashikuese në të dhëna të reja.

Fjalë kyçe: analizë përshkruese; regresion linear; OLS; performancë akademike; korrelacion; residuals.

I. Hyrje

Vlerësimi i performancës së nxënësve është çështje e rëndësishme në analizën e të dhënave arsimore. Notat e marra gjatë vitit mund të japin informacion mbi rezultatin përfundimtar, por marrëdhëniet midis tyre duhen matur dhe interpretuar në mënyrë sistematike. Studimi përdor të dhëna reale nga dy shkolla portugeze, të publikuara për qëllime kërkimore nga Cortez dhe Silva [1], [2].

Motivimi i punimit është përdorimi i metodave të thjeshta, të riprodhueshme dhe të interpretueshme për të kuptuar se sa lidhen vlerësimet e ndërmjetme me notën përfundimtare. Sfida kryesore është të dallojmë lidhjen statistikore nga interpretimi shkakësor dhe të vlerësojmë kufizimet e një modeli të ndërtuar mbi të njëjtat observime.

Kontributi i këtij projekti është realizimi i një procesi të plotë analitik: kontroll i dataset-it, klasifikim i variablave, identifikim i vlerave ekstreme, analiza përshkruese dhe korrelative, ndërtim i dy modeleve OLS dhe verifikim grafik i mbetjeve. Krahasimi i modeleve tregon në mënyrë të matshme sa informacion shtesë ofron G1 kundrejt përdorimit vetëm të G2.

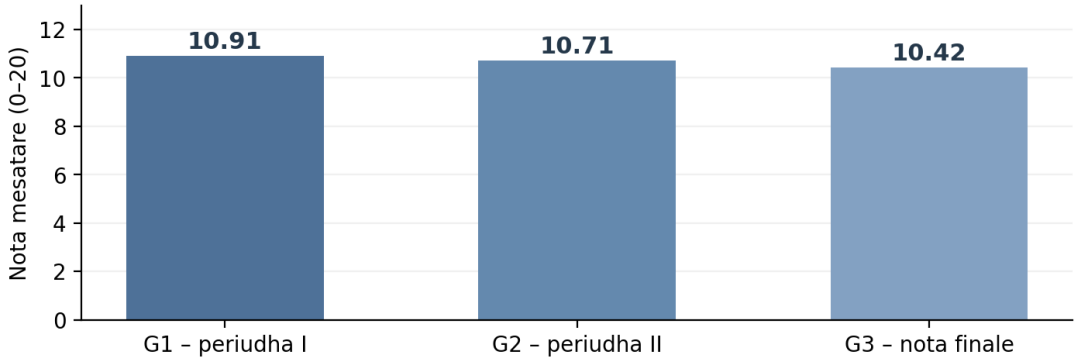


Figura 1. Mesataret e notave në tri periudhat e vlerësimit (llogaritje nga dataset-i [1]).

Figura 1 ilustron një rënie të lehtë të mesatares nga G1 (10.91) te G2 (10.71) dhe G3 (10.42). Ky është një përshkrim i të dhënave, jo provë e një rënieje shkakësore të performancës.

II. Qëllimi i punimit

Pyetja kërkimore dhe hipotezat

Pyetja kërkimore: A ekziston një lidhje lineare statistikisht domethënëse ndërmjet notave G1 dhe G2 dhe notës përfundimtare G3?

H_0: Koeficientët e G1 dhe G2 në modelin e shumëfishtë janë të dy zero ($\beta_1 = \beta_2 = 0$).

H_1: Të paktën njëri nga koeficientët është i ndryshëm nga zero.

Niveli i rëndësisë statistikore është $\alpha = 0.05$. Në analizën e regresionit të thjeshtë testohet veçmas lidhja e G2 me G3.

Burimi i të dhënave dhe teknologjitë

Përdoret skedari student-mat.csv nga koleksioni Student Performance në UCI Machine Learning Repository, i krijuar për analizimin e rezultateve shkollore në Portugali [1], [2]. Të dhënat janë të marra nga një burim publik; në këtë projekt nuk janë zhvilluar anketime të reja.

Mjedisi i punës është Visual Studio Code me Jupyter Notebook (.ipynb), duke përdorur Python. Pandas dhe NumPy shërbejnë për ngarkimin dhe përpunimin e të dhënave; Matplotlib dhe Seaborn për grafikët; ndërsa Statsmodels për regresionin OLS dhe analizën e rezultateve [4]. Ky kombinim lejon dokumentimin e hapave dhe riprodhimin e analizës.

Metodologjia e përdorur

Faza	Metoda / Produkti
1. Përgatitja	Ngarkim me pandas; verifikim i 395 rreshtave dhe 33 kolonave.
2. Cilësia	Missing values, rreshta identikë dhe zbulim i outliers me IQR.
3. Përshkrimi	Mesatare, medianë, devijim standard, histogram, scatter plot dhe boxplot.
4. Modelimi	OLS i thjeshtë (G2 → G3) dhe OLS i shumëfishtë (G1, G2 → G3).
5. Vlerësimi	Koeficientë, p-value, R^2, adjusted R^2 dhe grafikat e mbetjeve.

Kufizim metodologjik: G1 dhe G2 janë rezultate të marra para vlerësimit final dhe lidhen ngushtë me G3. Prandaj kjo analizë synon kryesisht shpjegimin e lidhjeve dhe jo parashikimin e hershëm të suksesit [1].

III. Pjesa kryesore

3.1. Dataset-i dhe klasifikimi sipas Stevens

Dataset-i student-mat.csv përmban 395 observime dhe 33 variabla demografike, familjare, shkollore dhe akademike. Variablat G1 dhe G2 janë notat e periudhave të para, ndërsa G3 është nota përfundimtare (shkalla 0–20). Shkallët e matjes janë klasifikuar në katër kategori, duke u mbështetur në kornizën e Stevens [3].

Variabla	Shkalla	Variabla	Shkalla
school	Nominale	Medu	Ordinale
sex	Nominale	Fedu	Ordinale
address	Nominale	traveltime	Ordinale
Pstatus	Nominale	studytime	Ordinale
Mjob	Nominale	failures	Ordinale
Fjob	Nominale	famrel	Ordinale
reason	Nominale	freetime	Ordinale
guardian	Nominale	goout	Ordinale
schoolsup	Nominale	Dalc	Ordinale
famsup	Nominale	Walc	Ordinale
paid	Nominale	health	Ordinale
activities	Nominale	G1	Interval
nursery	Nominale	G2	Interval
higher	Nominale	G3	Interval
internet	Nominale	age	Raport
romantic	Nominale	absences	Raport
famsize	Ordinale		

Tabela 1. Klasifikimi i 33 variablave: 16 nominale, 12 ordinale, 3 interval dhe 2 raport. Notat 0–20 trajtohen si intervale numerike; klasifikimi i disa variablave me kategori të renditura (p.sh. famsize dhe failures) varet nga mënyra e operacionalizimit të tyre.

3.2. Pastrimi i të dhënave dhe analiza përshkruese

Kontrolli i cilësisë u krye mbi dataset-in origjinal. Nuk u gjetën vlera të munguara dhe as rreshta plotësisht të dyfishuar. Outliers u identifikuan me kufijtë Q1 − 1.5×IQR dhe Q3 + 1.5×IQR; këto sinjalizime nuk konsiderohen automatikisht gabime.

Kontrolli	Rezultati	Veprimi
Missing values	0	Pa imputim / fshirje
Duplikata identike	0	Pa fshirje
Outliers në age	1 (vlera 22)	U ruajt
Outliers në absences	15 (21–75)	U ruajt
Outliers në G2	13 (vlera 0)	U ruajt

Tabela 2. Kontrolli i cilësisë së të dhënave dhe trajtimi i vlerave ekstreme.

Vlerat e identifikuara janë brenda intervaleve të dokumentuara të dataset-it dhe nuk u gjet evidencë se përbëjnë gabime [1]. Dataset-i final mbeti 395 × 33; numri 29 përfaqëson identifikime, jo domosdoshmërisht nxënës të ndryshëm.

Statistikat kryesore

Variabla	Mesatarja	Mediana	Dev. stand.	Min–Max
age	16.70	17	1.28	15–22
absences	5.71	4	8.00	0–75
G1	10.91	11	3.32	3–19
G2	10.71	11	3.76	0–19
G3	10.42	11	4.58	0–20

Tabela 3. Statistikat përshkruese të variablave kryesore.

Nota finale ka devijimin standard më të lartë nga G1/G2/G3 (4.58), ndërsa mesatarja e saj është 10.42. Korrelacionet Pearson tregojnë G1–G2 = 0.852, G1–G3 = 0.801 dhe G2–G3 = 0.905.

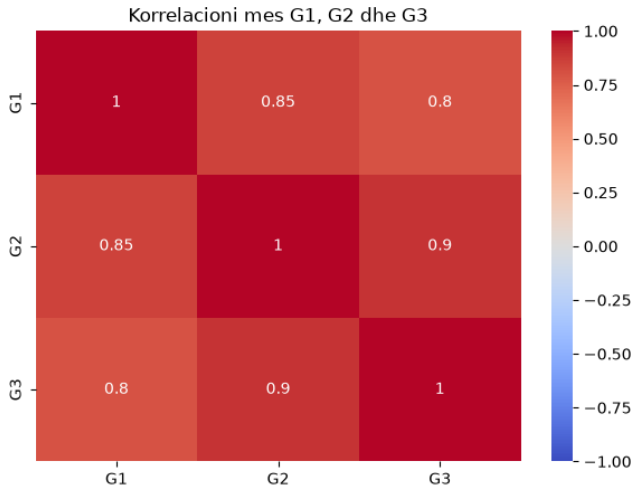


Figura 2. Matrica e korrelacionit Pearson për G1, G2 dhe G3 (rezultat i analizës).

3.3. Modelimi me regresion linear

Për vlerësimin e lidhjes statistikore u përdor OLS me G3 si variabël të varur. Koeficientët, niveli i rëndësisë dhe R^2 janë llogaritur me Statsmodels, mbi të njëjtat 395 observime.

Modeli i thjeshtë: G2 → G3

$$\hat{G3} = -1.3928 + 1.1021 \times G2$$

Koeficienti i G2 është pozitiv: një pikë më shumë në G2 shoqërohet me rreth 1.10 pikë më shumë në vlerën e parashikuar të G3. P-value = 7.63×10^{-148} dhe $R^2 = 0.8188$ (81.88%).

Modeli i shumëfishtë: G1 + G2 → G3

$$\hat{G3} = -1.8300 + 0.1533 \times G1 + 0.9869 \times G2$$

Duke e mbajtur G2 konstante, një pikë më shumë në G1 lidhet me rreth 0.153 pikë më shumë në G3. Duke e mbajtur G1 konstante, një pikë më shumë në G2 lidhet me rreth 0.987 pikë më shumë në G3.

Treguesi	Modeli i thjeshtë	Modeli i shumëfishtë
Variablat shpjeguese	G2	G1 + G2
R^2	0.8188	0.8222
Adjusted R^2	0.8183	0.8213
Koeficienti G1	—	0.1533 (p = 0.00665)
Koeficienti G2	1.1021	0.9869 ($p \approx 1.90 \times 10^{-61}$)
Testi F - p-value	—	$\approx 1.01 \times 10^{-147}$

Tabela 4. Krahasimi i regresionit linear të thjeshtë dhe të shumëfishtë, bazuar në rezultatet e notebook-ut.

Interpretimi i hipotezave

Të dy koeficientët e modelit të shumëfishtë kanë $p < 0.05$; testi F për modelin është gjithashtu statistikisht domethënës. Refuzohet H_0 ($\beta_1 = \beta_2 = 0$). Megjithatë, shtimi i G1 rrit R^2 vetëm me 0.00338 (rreth 0.34 pikë përqindjeje), kështu që përfitimi praktik në shpjegimin e variacionit është i vogël.

R^2 dhe gabimet janë matur mbi të dhënat e përdorura për përshtatjen e modelit. Ato nuk duhen interpretuar si performancë e verifikuar për nxënës të rinj.

3.4. Analiza e mbetjeve (residuals)

Mbetja është diferenca mes notës reale dhe asaj të parashikuar. Mesatarja e mbetjeve është praktikisht 0; devijimi standard është 1.932, MAE = 1.138 dhe RMSE = 1.930 pikë. Grafikat e mëposhtme i referohen modelit të shumëfishtë.

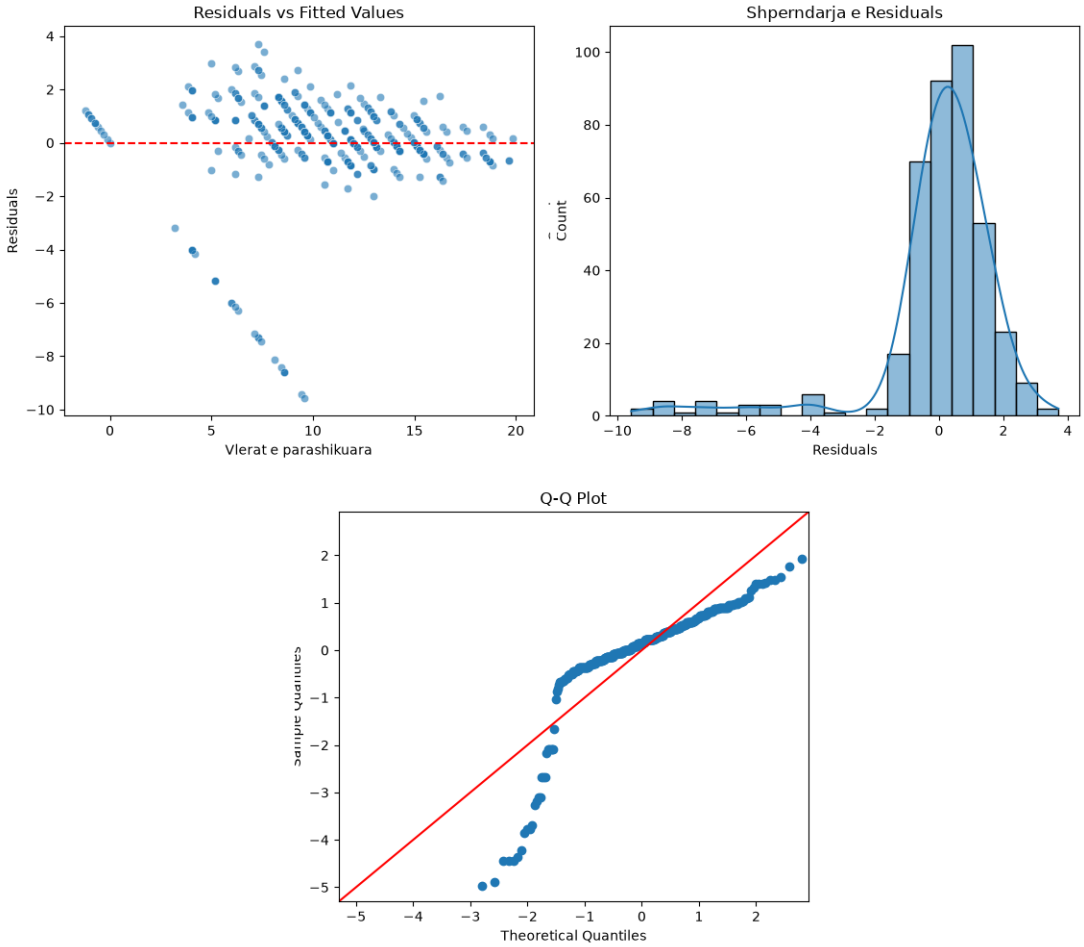


Figura 3. Residuals vs Fitted, histogrami dhe Q-Q plot i mbetjeve (rezultat nga notebook-u).

Në grafikun Residuals vs Fitted dallohen disa mbetje shumë negative. Histogrami është asimetrik me bisht të gjatë majtas, ndërsa pikat në Q-Q plot devijojnë nga vija e referencës në bishtat e shpërndarjes. Kjo sinjalizon mospërputhje me supozimin e normalitetit dhe kërkon kujdes me inferencën standarde të OLS.

IV. Konkluzione (Përfundim)

Qëllimi i projektit u arrit: u analizuan 395 observime, u klasifikuan 33 variabla dhe u ndërtuan dy modele lineare të interpretueshme. Lidhja G2–G3 ishte shumë e fortë (r = 0.905). Modeli i thjeshtë shpjegoi 81.88% të variacionit të G3, ndërsa modeli me G1 dhe G2 shpjegoi 82.22%. Rezultatet mbështesin hipotezën alternative për lidhjen statistikore të notave.

Kufizimet kryesore janë devijimet në mbetje, mungesa e testimit jashtë kampionit dhe fakti që korrelacioni nuk provon shkakësi. Si punë e ardhshme rekomandohet ndarja train/test, validimi kryq, testimi i modeleve pa G1 dhe G2 për parashikim më të hershëm dhe përdorimi i gabimeve standarde robuste.

Referencat

[1] Cortez, P. (2008). Student Performance [Dataset]. UCI Machine Learning Repository. DOI: 10.24432/C5TG7T. https://archive.ics.uci.edu/dataset/320/student+performance (qasur: 28.10.2026).

[2] Cortez, P., & Silva, A. (2008). Using Data Mining to Predict Secondary School Student Performance. In Proceedings of the 5th Future Business Technology Conference (FUBUTEC 2008), f. 5–12.

[3] Stevens, S. S. (1946). On the Theory of Scales of Measurement. Science, 103(2684), 677–680. https://doi.org/10.1126/science.103.2684.677

[4] Statsmodels Developers. Linear Regression – Ordinary Least Squares (OLS). https://www.statsmodels.org/stable/regression.html (qasur: 28.10.2026).

Materiali shoqërues i projektit

• Notebook: analysis.ipynb (kodi, rezultatet dhe figurat)

• Dataset: data/student-mat.csv (burimi i cituar në [1])

• Repository GitHub: https://github.com/valonhajrediniii/data-analysis-project-1

• Dokumentimi teknik: ky raport dhe versioni PDF